Seminar I - Vergleiche der Verfahren

Mirco Buck

October 2026

1 Literaturrecherche zu neuronalen Netzarchitekturen und Trainingsverfahren

1.1 Zielsetzung und Bewertungsmethodik

Ziel der Literaturrecherche ist es, geeignete neuronale Netzarchitekturen und Trainingsverfahren für den Einsatz als Ersatzmodelle (Surrogate Models) für strukturmechanische Berechnungen zu identifizieren. Die eigentliche Finite-Elemente-Methode (FEM) soll dabei durch ein trainiertes neuronales Netz ergänzt beziehungsweise für wiederkehrende Berechnungen ersetzt werden, um den Rechenaufwand bei der Untersuchung unterschiedlicher Modellvarianten zu reduzieren.

Als erste Problemstellung dient ein einseitig eingespannter Biegebalken. Die Eingangsgrößen umfassen geometrische Parameter, Materialeigenschaften und die äußere Belastung. Als Ausgangsgröße wird zunächst die statische Auslenkung des Balkens betrachtet. Im weiteren Verlauf können zusätzliche Zielgrößen wie Eigenfrequenzen berücksichtigt werden.

Die Eignung der verschiedenen Ansätze wird anhand folgender Kriterien bewertet:

- **Vorhersagegenauigkeit:** Fähigkeit, die Ergebnisse der analytischen Berechnung beziehungsweise der FEM hinreichend genau zu approximieren.
- **Datenbedarf:** Anzahl der erforderlichen Referenzberechnungen, um eine ausreichend genaue Vorhersage zu ermöglichen.
- **Trainingsaufwand:** Rechenzeit und Ressourcenbedarf für das Training des neuronalen Netzes.
- **Generalisierungsfähigkeit:** Fähigkeit, auch für bisher unbekannte Kombinationen aus Geometrie, Material und Belastung zuverlässige Vorhersagen zu liefern.
- **Implementierungsaufwand:** Aufwand für die Umsetzung und Untersuchung des jeweiligen Ansatzes in MATLAB.

Zur vergleichenden Bewertung wird eine Skala von 1 bis 10 verwendet. Dabei entspricht eine Bewertung von 1 einer sehr geringen und eine Bewertung von 10 einer sehr hohen Eignung. Die nachfolgenden Bewertungen stellen vorläufige Einschätzungen für die betrachtete Problemstellung dar und müssen im Rahmen der Literaturrecherche anhand wissenschaftlicher Quellen überprüft werden.

1.2 Neuronale Netzarchitekturen

1.2.1 Feedforward-Netze und Multi-Layer Perceptrons

Feedforward-Netze bilden eine grundlegende Klasse künstlicher neuronaler Netze. Eine verbreitete Ausprägung ist das Multi-Layer Perceptron (MLP), das aus einer Eingabeschicht, einer oder mehreren verborgenen Schichten und einer Ausgabeschicht besteht.

Die Eingangsdaten werden schichtweise verarbeitet. Jedes Neuron bildet eine gewichtete Summe seiner Eingänge und wendet darauf eine Aktivierungsfunktion an. Durch die Kombination mehrerer Schichten und nichtlinearer Aktivierungsfunktionen können komplexe Zusammenhänge zwischen Eingangs- und Ausgangsgrößen approximiert werden.

Die Parameter des Netzes werden während des Trainings so angepasst, dass die Abweichung zwischen den vorhergesagten und den bekannten Referenzwerten möglichst gering wird.

Für die betrachtete Problemstellung eignet sich ein MLP besonders gut, da die Eingangsgrößen aus einer begrenzten Anzahl geometrischer und materialbezogener Parameter sowie der Belastung bestehen. Die Ausgabe kann beispielsweise die maximale Balkenauslenkung oder eine ausgewählte Eigenfrequenz darstellen.

1.2.2 Radial Basis Function Networks

Radial Basis Function Networks (RBF-Netze) verwenden Neuronen mit radialen Basisfunktionen in einer verborgenen Schicht. Eine häufig verwendete Funktion ist die Gaußfunktion. Ihre Aktivierung hängt vom Abstand zwischen dem Eingangsvektor und einem festgelegten Zentrum ab.

Die Ausgangswerte werden anschließend durch eine gewichtete Kombination dieser Aktivierungen bestimmt. Dadurch können nichtlineare Zusammenhänge zwischen den Eingangs- und Ausgangsgrößen approximiert werden.

RBF-Netze können bei geeigneter Wahl der Zentren und ihrer Breiten eine gute Approximation erreichen. Allerdings kann die Anzahl benötigter Neuronen mit der Komplexität des Problems und der Größe des Eingangsraums deutlich steigen.

Für den Biegebalken stellen RBF-Netze eine interessante Alternative zum MLP dar, insbesondere für Vergleichsuntersuchungen bei einer begrenzten Anzahl von Eingangsparametern.

1.2.3 Convolutional Neural Networks

Convolutional Neural Networks (CNNs) wurden insbesondere für die Verarbeitung räumlich strukturierter Daten entwickelt. Sie verwenden Faltungsoperationen, um lokale Muster in den Eingangsdaten zu erkennen. Durch mehrere Faltungsschichten können hierarchische Merkmale extrahiert werden.

Bei strukturmechanischen Anwendungen können CNNs beispielsweise auf räumlich verteilte Felder wie Verschiebungen, Spannungen oder Dehnungen angewendet werden. Auch die Verarbeitung regelmäßiger Rasterdarstellungen geometrischer Informationen ist möglich.

Für die erste Untersuchung eines Biegebalkens mit wenigen skalaren Eingangsparametern ist ein CNN allerdings nicht zwingend erforderlich. Seine Vorteile werden insbesondere dann interessant, wenn räumliche Feldgrößen oder komplexere Geometrien berücksichtigt werden sollen.

1.2.4 Rekurrente neuronale Netze

Rekurrente neuronale Netze (RNNs) besitzen Verbindungen, durch die Informationen aus vorherigen Verarbeitungsschritten berücksichtigt werden können. Sie sind daher insbesondere für sequenzielle Daten geeignet. Erweiterte Varianten wie Long Short-Term Memory (LSTM) können Informationen über längere Sequenzen speichern.

In der Strukturmechanik können solche Netze beispielsweise bei zeitabhängigen Belastungen, dynamischen Systemantworten oder zeitlichen Verläufen von Verschiebungen eingesetzt werden.

Für die zunächst betrachtete statische Auslenkung eines Biegebalkens ist diese Architektur aufgrund der fehlenden zeitlichen Abhängigkeit nicht erforderlich. Bei einer späteren Erweiterung auf dynamische Simulationen kann sie jedoch relevant werden.

1.2.5 Physics-Informed Neural Networks

Physics-Informed Neural Networks (PINNs) berücksichtigen neben vorhandenen Referenzdaten auch bekannte physikalische Zusammenhänge während des Trainings. Dazu können beispielsweise Differentialgleichungen, Randbedingungen und Anfangsbedingungen in eine zusätzliche Verlustfunktion aufgenommen werden.

Das Netz wird so trainiert, dass sowohl die Abweichung von bekannten Referenzwerten als auch die Verletzung der zugrunde liegenden physikalischen Gleichungen möglichst gering ist.

Für einen einseitig eingespannten Biegebalken können beispielsweise die Balkengleichung und die zugehörigen Randbedingungen berücksichtigt werden. Dadurch besteht die Möglichkeit, physikalisches Vorwissen direkt in das Modell einzubringen.

Allerdings erfordert die Implementierung die geeignete Formulierung der physikalischen Gleichungen und ihrer Beiträge zur Verlustfunktion. Außerdem

ist nicht garantiert, dass ein PINN mit weniger Daten oder geringerem Trainingsaufwand eine höhere Genauigkeit als ein konventionelles MLP erreicht.

1.3 Vergleich der Netzarchitekturen

Die folgende Tabelle enthält eine vorläufige Bewertung der vorgestellten Architekturen für die betrachtete Problemstellung. Die Werte dienen als Ausgangspunkt für die Literaturrecherche und stellen keine experimentellen Ergebnisse dar.

Table 1: Vorläufige Bewertung neuronaler Netzarchitekturen

Architektur	**Genauigkeit**	**Datenbedarf**	**Training**	**General.**	**Eignung**
MLP	9	7	9	9	10
RBF	8	8	8	7	8
CNN	8	5	6	8	5
RNN/LSTM	7	5	5	7	3
PINN	8	8	5	8	7

Hinweis: Bei den Kriterien Datenbedarf und Trainingsaufwand bedeutet eine hohe Punktzahl einen geringen erforderlichen Aufwand. Die Genauigkeit und Generalisierungsfähigkeit sind als Potenzial bei geeigneter Modellierung zu verstehen. Die tatsächliche Leistung hängt unter anderem von der Architektur, den Trainingsdaten und der Problemkomplexität ab.

Das MLP stellt für die erste Untersuchung die aussichtsreichste Ausgangsbasis dar. Es kann mit überschaubarem Implementierungsaufwand auf tabellarische Eingangsparameter angewendet werden und ermöglicht eine systematische Untersuchung der Anzahl verborgener Schichten, der Neuronenzahl und der Aktivierungsfunktionen.

RBF-Netze bieten eine sinnvolle Vergleichsmöglichkeit. CNNs und RNNs sind dagegen vor allem für spätere Erweiterungen auf räumlich verteilte beziehungsweise zeitabhängige Daten interessant. PINNs sollten zusätzlich betrachtet werden, wenn der Nutzen physikalischer Nebenbedingungen untersucht werden soll.

1.4 Trainingsverfahren

Neben der Netzarchitektur beeinflusst das Trainingsverfahren die Vorhersagegenauigkeit, die Konvergenz und den erforderlichen Rechenaufwand. Beim überwachten Training werden Eingabedaten mit bekannten Referenzwerten verwendet. Die Netzparameter werden so angepasst, dass eine gewählte Verlustfunktion minimiert wird.

Für die Approximation der Balkenauslenkung kann beispielsweise der mittlere quadratische Fehler (Mean Squared Error, MSE) verwendet werden:

$$\mathrm{MSE} = \frac{1}{N} \sum_{i=1}^{N} \left(y_i - \hat{y}_i \right)^2 , \tag{1}$$

wobei N die Anzahl der Trainingsbeispiele, y_i den jeweiligen Referenzwert und $\hat{y}_i$ den vom neuronalen Netz vorhergesagten Wert bezeichnet.

1.4.1 Gradientenabstiegsverfahren

Beim klassischen Gradientenabstieg werden die Netzparameter schrittweise entgegen der Richtung des Gradienten der Verlustfunktion angepasst. Die Lernrate bestimmt dabei die Größe der einzelnen Aktualisierungen.

Bei großen Datensätzen kann die Berechnung des Gradienten über sämtliche Trainingsdaten aufwendig sein. Daher werden häufig stochastische oder mini-batch-basierte Varianten eingesetzt, bei denen nur ein Teil der Trainingsdaten zur jeweiligen Aktualisierung verwendet wird.

Das Verfahren bildet die Grundlage vieler moderner Optimierungsverfahren. Die Wahl der Lernrate und der Batchgröße beeinflusst sowohl die Konvergenzgeschwindigkeit als auch die Stabilität des Trainings.

1.4.2 Stochastic Gradient Descent und Momentum

Beim Stochastic Gradient Descent (SGD) werden die Parameter anhand einzelner Trainingsbeispiele oder kleiner Teilmengen der Trainingsdaten aktualisiert. Dadurch lassen sich die einzelnen Aktualisierungsschritte mit vergleichsweise geringem Rechenaufwand durchführen.

Die Momentum-Erweiterung berücksichtigt zusätzlich einen Anteil vorheriger Aktualisierungsrichtungen. Dadurch können ungünstige Schwankungen reduziert und die Optimierung in konsistenten Gradientenrichtungen beschleunigt werden.

SGD mit Momentum ist ein etablierter Vergleichsansatz. Die Wahl geeigneter Lernraten und deren Anpassung während des Trainings können jedoch zusätzlichen Abstimmungsaufwand erfordern.

1.4.3 Adam

Adaptive Moment Estimation (Adam) kombiniert Schätzungen des ersten und zweiten Moments der Gradienten, um die Parameter adaptiv zu aktualisieren. Dadurch erhält jede Parameterkomponente eine an ihre bisherigen Gradienten angepasste Aktualisierung.

Adam wird häufig bei neuronalen Netzen eingesetzt, da es in vielen Anwendungen mit vergleichsweise wenig manueller Abstimmung gute Ergebnisse liefert.

Für die Untersuchung des Biegebalkens eignet sich Adam als Ausgangspunkt für das Training eines MLP. Insbesondere bei unterschiedlichen Netzgrößen kann das Verfahren als einheitlicher Optimierer für Vergleichsexperimente dienen.

1.4.4 Levenberg-Marquardt-Verfahren

Das Levenberg-Marquardt-Verfahren ist ein Optimierungsverfahren, das insbesondere bei nichtlinearen Ausgleichsproblemen eingesetzt wird. Es kombiniert

Eigenschaften des Gradientenabstiegs mit Eigenschaften des Gauß-Newton-Verfahrens.

Für neuronale Netze kann das Verfahren bei geeigneter Formulierung der Fehlerfunktion eine schnelle Konvergenz ermöglichen. Es kann vor allem bei kleinen bis mittelgroßen Netzen mit überschaubaren Datensätzen interessant sein.

Der Nachteil liegt im erhöhten Speicher- und Rechenbedarf, der durch die approximierte Krümmungsinformation entsteht. Bei großen Netzen kann dies die praktische Anwendbarkeit einschränken.

1.4.5 Bayesian Regularization

Bayesian Regularization bezeichnet einen Ansatz zur Regularisierung des Trainings. Dabei werden neben dem Datenfehler auch die Größe der Netzgewichte berücksichtigt. Eine typische Zielfunktion besitzt die Form

$$F(w) = \beta E_D + \alpha E_W, \tag{2}$$

wobei E_D den Datenfehler und E_W eine Strafgröße für die Netzgewichte bezeichnet. Die Parameter α und β gewichten die beiden Beiträge.

Die Regularisierung kann dazu beitragen, übermäßig komplexe Netzmodelle und damit eine Überanpassung an die Trainingsdaten zu vermeiden. Dies ist für Ersatzmodelle besonders relevant, da die Vorhersagequalität auch für bisher nicht verwendete Balkenvarianten gewährleistet sein soll.

Bayesian Regularization ist dabei kein eigenständiger Netztyp. Der Ansatz verändert die Zielfunktion beziehungsweise die Regularisierung des Trainings und kann mit geeigneten Optimierungsverfahren kombiniert werden.

1.5 Vergleich der Trainingsverfahren

Die folgende Tabelle enthält eine erste qualitative Bewertung der Trainingsverfahren für ein MLP, das die Auslenkung des Biegebalkens approximiert.

Table 2: Vorläufige Bewertung der Trainingsverfahren

Verfahren	**Konvergenz**	**Effizienz**	**Robustheit**	**Eignung**
SGD	6	8	6	7
SGD mit Momentum	7	8	7	8
Adam	9	9	8	10
Levenberg-Marquardt	9	5	7	8
Bayesian Regularization	8	6	9	8

Hinweis: Eine hohe Bewertung bei Konvergenz bedeutet eine erwartete schnelle Konvergenz. Eine hohe Effizienz entspricht einem geringen Rechenaufwand. Die Robustheit beschreibt die erwartete Stabilität gegenüber ungünstigen Trainingsbedingungen und Überanpassung. Die Bewertungen sind problemabhängige Einschätzungen und müssen anhand der Literatur sowie späterer Experimente überprüft werden.

Adam ist ein geeigneter Ausgangspunkt, da es in vielen Anwendungen eine gute Kombination aus Konvergenzgeschwindigkeit und Implementierungsaufwand bietet. SGD mit Momentum stellt eine Alternative für Vergleichsuntersuchungen dar. Das Levenberg-Marquardt-Verfahren ist vor allem für kleinere Netze interessant, während Bayesian Regularization insbesondere zur Untersuchung der Generalisierungsfähigkeit berücksichtigt werden kann.

1.6 Versuchsplanung und Validierung

Für einen systematischen Vergleich der Architekturen und Trainingsverfahren sollten die folgenden Einflussgrößen untersucht werden:

- **Netzarchitektur:** Anzahl verborgener Schichten, Anzahl der Neuronen pro Schicht und verwendete Aktivierungsfunktionen.
- **Trainingsparameter:** Lernrate, Batchgröße, Abbruchkriterien und gegebenenfalls Regularisierungsparameter.
- **Trainingsdatensatz:** Anzahl und Verteilung der Referenzberechnungen sowie die Variation der geometrischen, materialbezogenen und mechanischen Eingangsgrößen.
- **Validierung:** Vergleich der Vorhersagen mit analytischen Lösungen beziehungsweise Referenzberechnungen, die nicht zum Training verwendet wurden.
- **Rechenaufwand:** Erfassung der Trainingsdauer und der benötigten Anzahl an Referenzberechnungen.

Die Daten sollten in Trainings-, Validierungs- und Testdaten unterteilt werden. Die Validierungsdaten dienen der Auswahl geeigneter Modellparameter, während die Testdaten ausschließlich für die abschließende Bewertung des trainierten Modells verwendet werden.

Als quantitative Kennzahlen eignen sich beispielsweise der mittlere absolute Fehler (MAE), der mittlere quadratische Fehler (MSE) und der relative Fehler. Bei einer Referenzgröße y_i kann der absolute Fehler durch

$$e_i = |y_i - \hat{y}_i| \tag{3}$$

bestimmt werden. Ergänzend sollte die Trainingszeit dokumentiert werden, um die Genauigkeit und den Rechenaufwand gemeinsam bewerten zu können.

1.7 Vorläufige Schlussfolgerung

Für die erste Untersuchung eines neuronalen Ersatzmodells für strukturmechanische Berechnungen erscheint ein Multi-Layer Perceptron in Kombination mit dem Optimierungsverfahren Adam besonders geeignet. Beide Ansätze ermöglichen einen überschaubaren Einstieg und lassen sich systematisch in MATLAB untersuchen.

Als ergänzende Vergleichsansätze bieten sich RBF-Netze und das Levenberg-Marquardt-Verfahren an. Bayesian Regularization kann zusätzlich zur Untersuchung der Generalisierungsfähigkeit herangezogen werden. PINNs stellen eine weiterführende Möglichkeit dar, physikalische Zusammenhänge in das Training einzubeziehen.

Die endgültige Auswahl sollte nicht allein anhand der theoretischen Bewertungen erfolgen. Entscheidend ist, welche Kombination aus Netzarchitektur und Trainingsverfahren bei vergleichbarem Trainingsaufwand die höchste Vorhersagegenauigkeit für bislang unbekannte Balkenvarianten erreicht. “‘